

Sompo Predict

Deep Learning — Sprint 2 · Semana 3

FIAP & Sompo Seguros

GRUPO T1 · ENGENHARIA DE IA

- Gustavo Reatti Sela** — RM 571545
- Charles Augusto Miranda da Silva** — RM 571908
- Anthony Prado Pereira** — RM 572985

- Rafael Gonçalves** — RM 569461
- Guilherme Araujo Pinto** — RM 569863
- Francisco Cândido** — RM 574165

| Recapitulando o Desafio

“IA para identificação de fatores ambientais e operacionais que aumentam o risco de dano ou perda de equipamentos agrícolas.”

Desafio proposto pela Sompó Seguros · 3ª maior seguradora de máquinas agrícolas do Brasil

Por que uma segunda família de modelo

O notebook de ML Modelling estabeleceu o baseline com Decision Tree. Aqui, testamos uma **Rede Neural (MLP)** sobre os mesmos dados e o mesmo split — uma comparação justa entre duas formas distintas de aprender o mesmo problema.

Objetivo

Identificar fatores ambientais e operacionais que elevam o risco de danos em equipamentos agrícolas, e gerar um score de risco explicável por equipamento, operação e região.

Problema de Deep Learning

Mesma classificação multiclasse (`CLASSIFICACAO_RISCO`), agora resolvida por uma **Rede Neural densa (MLP/Keras)** — mesmo pipeline de pré-processamento e mesmo split (`random_state=42`) do notebook de ML Modelling, para garantir comparação válida.

Foco da Sprint

Treinar e avaliar a rede com **honestidade metodológica**, documentando arquitetura, curvas de treino/validação e o resultado real no teste — sem inflar números.

| Dataset Base: SUSEP Rural

Mesma base utilizada no notebook de ML Modelling — garante comparação justa entre os dois modelos

149

OBSERVAÇÕES

08

VARIÁVEIS ORIGINAIS

100%

DADOS REAIS

Fonte e Origem


Dados estatísticos oficiais de seguros rurais fornecidos pela SUSEP, garantindo confiabilidade e rastreabilidade.

Classes de Risco (alvo)

- Baixo · 67
- Médio · 42
- Alto · 28
- Crítico · 12

VARIÁVEL	TIPO	DESCRIÇÃO
UF	Categ. nominal	Estado da apólice (8 estados)
RAMO_SUSEP	Categ. nominal	Ramo do seguro rural (4 ramos)
CLASSIFICACAO_RISCO	Categ. ordinal (alvo)	Nível de risco atribuído à apólice
INTENSIDADE_SINISTRO	Categ. ordinal	Gravidade do sinistro histórico
IDADE_MAQUINA_ANOS	Num. contínua	Idade do equipamento agrícola
ACESSORIOS_SEGURADOS	Num. discreta	Acessórios cobertos pela apólice
PREMIO_LIQUIDO_BRL	Num. contínua	Valor do prêmio pago (R\$)
VALOR_INDENIZADO_BRL	Num. contínua	Pago em sinistro — removida do modelo (leakage)

| Análise Exploratória (EDA)



INSIGHT 1

Concentração geográfica do risco

Goiás (GO) concentra Loss Ratio médio de **32,5** — muito acima da média nacional. Rio Grande do Sul e Paraná operam abaixo do break-even ($LR < 1,0$). **UF é um preditor categórico relevante** — mesma leitura do notebook de ML Modelling.

INSIGHT 2

Classificação “Crítico” se valida nos dados

Apólices Crítico têm Loss Ratio médio de **75,9** — dezenas de vezes maior que os demais níveis. O rótulo é **validado contra o resultado real**, independentemente do algoritmo usado para prevê-lo.

POR QUE REPETIR A EDA

Mesma base, comparação justa

Este notebook de Deep Learning usa exatamente a mesma base e os mesmos achados de EDA do notebook de ML Modelling — a EDA completa (3 gráficos detalhados) está documentada lá. Aqui o foco é a rede neural.

| Pré-processamento

Mesmo pipeline do notebook de ML Modelling — os 3 pontos do feedback da Sprint 1 seguem corrigidos

104

AMOSTRAS TREINO

45

AMOSTRAS TESTE

14

FEATURES FINAIS

1 · FEEDBACK SPRINT 1

Desbalanceamento

Crítico = 8% da base (12 obs). O mesmo teste empírico do notebook de ML Modelling se aplica aqui: a classe rara continua sendo o ponto cego, agora confirmado também pela rede neural (recall 0,00 para Crítico no teste).

2 · FEEDBACK SPRINT 1

Encoding & Normalização


Mesmo encoding (ordinal + one-hot). A diferença aqui: `StandardScaler` deixa de ser apenas documentado e passa a ser **obrigatório** — sem ele, o gradiente do MLP é dominado pela escala de `PREMIO_LIQUIDO_BRL` (~R\$ 400 mil) e o treino não converge.

3 · FEEDBACK SPRINT 1

Estratégia de Validação

Split **70/30 estratificado** (`random_state=42`) idêntico ao notebook de ML Modelling. Para a rede, 20% adicionais do treino são reservados como validação interna, usada pelo `EarlyStopping` para decidir quando parar o treino.

| Arquitetura da Rede



Por que essa arquitetura

Rede pequena (1.076 parâmetros) e proposital: com apenas 104 amostras de treino, uma rede profunda decoraria o treino em poucas épocas. Duas camadas densas (32 → 16) capturam combinações não-lineares simples entre as 14 features.


Papél do Dropout

Dropout de 30% e 20% desliga neurônios aleatoriamente a cada passo — a principal defesa contra overfitting numa base pequena, junto com o Early Stopping (paciência de 15 épocas sobre `val_loss`).

Saída Softmax

4 neurônios de saída (um por classe) com softmax produzem uma distribuição de probabilidade — compatível com `categorical_crossentropy`, padrão para classificação multiclasse.

| Curvas de Treino e Validação



Early Stopping interrompeu na época 51

De um limite de 150 épocas, o treino parou aos **51** após 15 épocas sem melhora em `val_loss`, restaurando os pesos do melhor ponto encontrado.


Loss cai de forma consistente

Tanto a loss de treino quanto a de validação decrescem ao longo das épocas, sem divergência abrupta entre as duas — não há sinal claro de overfitting severo dentro da janela de treino observada.

Acurácia de validação é ruidosa — e isso é esperado

O conjunto de validação interna tem apenas **~21 amostras** (20% de 104). Com tão poucos exemplos, cada acerto ou erro individual move a métrica em saltos discretos — os “degraus” no gráfico de acurácia refletem o tamanho da amostra, não instabilidade do modelo.

| Resultados e Interpretação



Resultado real, sem maquiagem: 42,2% de acurácia em teste — muito próximo do baseline ingênuo (44,4%). F1 weighted = 0,37.

MLP vs. Decision Tree

Em acurácia bruta, a MLP fica praticamente no nível do baseline — não supera, mas também não fica abaixo como a Decision Tree (26,7%). Em **F1 weighted** a rede vence claramente: **0,37 vs. 0,26**, refletindo previsões mais equilibradas entre as classes Baixo, Médio e Alto.

O ponto cego se repete

Assim como a Decision Tree, a MLP **nunca identifica corretamente** a classe Crítico (recall 0,00, 4 amostras no teste) — justamente a classe mais relevante para o negócio. Duas famílias de modelo diferentes chegando ao mesmo ponto cego reforça que o problema é o dado disponível, não o algoritmo.

Interpretação & Próximos Passos

Os 7 atributos operacionais atuais não carregam sinal suficiente para nenhum dos dois modelos testados. A Sprint 3 já prevê o caminho certo: **telemetria real (ESP32)**, **clima (Open-Meteo)**, **SHAP** para explicabilidade e mais volume de dados.