

Sompo Predict

ML Modelling — Sprint 2 · Semana 3

FIAP & Sompo Seguros

GRUPO T1 · ENGENHARIA DE IA

- Gustavo Reatti Sela** — RM 571545
- Charles Augusto Miranda da Silva** — RM 571908
- Anthony Prado Pereira** — RM 572985

- Rafael Gonçalves** — RM 569461
- Guilherme Araujo Pinto** — RM 569863
- Francisco Cândido** — RM 574165

| Recapitulando o Desafio

“IA para identificação de fatores ambientais e operacionais que aumentam o risco de dano ou perda de equipamentos agrícolas.”

Desafio proposto pela Sompo Seguros · 3ª maior seguradora de máquinas agrícolas do Brasil

Por que isso importa para a Sompo

Hoje a gestão de risco é majoritariamente reativa: a análise acontece depois do sinistro, com o prejuízo já consumado. Um score preventivo e explicável permite repricing regional, alocação de inspeções e retenção de portfólio mais rentável.

Objetivo

Identificar fatores ambientais e operacionais que elevam o risco de danos em equipamentos agrícolas, e gerar um score de risco explicável por equipamento, operação e região.

Problema de Machine Learning

Classificação supervisionada multiclasse. A variável-alvo `CLASSIFICACAO_RISCO` (Baixo / Médio / Alto / Crítico) é prevista a partir dos atributos operacionais e de subscrição disponíveis na apólice.

Foco da Sprint

Entregar o primeiro modelo baseline treinado e avaliado **com honestidade metodológica** — estabelecendo o ponto de partida real do projeto, incluindo as correções de pré-processamento apontadas no feedback da Sprint 1.

| Dataset Base: SUSEP Rural

149

OBSERVAÇÕES

08

VARIÁVEIS ORIGINAIS

100%

DADOS REAIS

Fonte e Origem

Dados estatísticos oficiais de seguros rurais fornecidos pela SUSEP, garantindo confiabilidade e rastreabilidade.

Qualidade e Tratamento

Base previamente saneada com remoção de outliers via IQR e ausência total de valores nulos — tratamento executado pelo membro Guilherme.

Classes de Risco (alvo)

- Baixo · 67


Médio · 42

Alto · 28

Crítico · 12

VARIÁVEL	TIPO	DESCRIÇÃO
UF	Categ. nominal	Estado da apólice (8 estados)
RAMO_SUSEP	Categ. nominal	Ramo do seguro rural (4 ramos)
CLASSIFICACAO_RISCO	Categ. ordinal (alvo)	Nível de risco atribuído à apólice
INTENSIDADE_SINISTRO	Categ. ordinal	Gravidade do sinistro histórico
IDADE_MAQUINA_ANOS	Num. contínua	Idade do equipamento agrícola
ACESSORIOS_SEGURADOS	Num. discreta	Acessórios cobertos pela apólice
PREMIO_LIQUIDO_BRL	Num. contínua	Valor do prêmio pago (R\$)
VALOR_INDENIZADO_BRL	Num. contínua	Pago em sinistro — removida do modelo (leakage)

| Análise Exploratória (EDA)



INSIGHT 1

Concentração geográfica do risco

Goiás (GO) concentra Loss Ratio médio de **32,5** — muito acima da média nacional. Rio Grande do Sul e Paraná operam abaixo do break-even ($LR < 1,0$), indicando portfólio mais rentável. **UF é um preditor categórico relevante.**

INSIGHT 2

Classificação “Crítico” se valida nos dados

Apólices Crítico têm Loss Ratio médio de **75,9** — dezenas de vezes maior que Baixo/Médio/Alto (1,1 a 1,5). O rótulo é **validado contra o resultado real**, embora a granularidade entre os três níveis inferiores possa ser revista.

DESBALANCEAMENTO

Crítico é raro e é o que mais importa

A classe mais relevante para o negócio (maior Loss Ratio) é também a mais rara: apenas 8% da base (12 apólices). Isso exige split estratificado — tratado na próxima seção.

| Pré-processamento

Três pontos do feedback da Sprint 1 corrigidos e documentados explicitamente nesta versão

104

AMOSTRAS TREINO

45

AMOSTRAS TESTE

14

FEATURES FINAIS

1 · FEEDBACK SPRINT 1

Desbalanceamento

Crítico = 8% da base (12 obs). Testamos `class_weight='balanced'` formalmente: a acurácia de teste **piorou** (26,7% → 11,1%). SMOTE foi descartado nesta sprint — base pequena demais para gerar amostras sintéticas confiáveis. **Decisão:** pesos padrão, com o teste documentado.

2 · FEEDBACK SPRINT 1

Encoding & Normalização


Ordinal em `INTENSIDADE_SINISTRO` e `CLASSIFICACAO_RISCO` — preserva a hierarquia natural. **One-Hot** (`drop_first=True`) em `UF` e `RAMO_SUSEP` — sem ordem natural entre categorias. `StandardScaler` aplicado às 3 numéricas contínuas **depois do split** (fit só no treino).

3 · FEEDBACK SPRINT 1

Estratégia de Validação

Split **70/30 estratificado** (`random_state=42`) preserva a proporção das 4 classes. Complementado com `cross_val_score` via `StratifiedKFold(5)` sobre o treino — média **31,7%**, confirmando que o resultado não é coincidência do split específico.

| Modelo, Métricas e Interpretação



Resultado real, sem maquiagem: 26,7% de acurácia em teste — abaixo do baseline ingênuo (44,4%, sempre prever “Baixo”). F1 weighted = 0,26.

Modelo

`DecisionTreeClassifier(max_depth=5, random_state=42)`, pesos padrão — escolhido após comparação formal com `class_weight='balanced'` (Seção de pré-processamento). Profundidade limitada controla overfitting numa base de 104 amostras de treino.

Validação cruzada confirma o resultado

Cross-validation 5-fold sobre o treino: média **31,7%** (desvio 0,02) — consistente com o resultado de teste. Não é um acaso do split 70/30 específico, é o nível real de sinal disponível nas features atuais.

Interpretação & Limitação

Os 7 atributos operacionais atuais **não carregam sinal suficiente** para reconstruir `CLASSIFICACAO_RISCO` — mas o rótulo é válido (Insight 2, pág. 4). Aponta direto para o que falta: **telemetria real (ESP32)**, **clima (Open-Meteo)** e **mais volume** — já previstos no roadmap da Sprint 3.